ГРНТИ 47.01.07, 47.01.09
ASJC 1707, 2207
OECD 1020, 1070

Исследование возможности детектирования светофоров

Л. С. Толстенко
кафедра инженерной кибернетики НИТУ «МИСиС»
Москва, Россия
m1805775@edu.misis.ru

А. А. Клейменов
кафедра инженерной кибернетики НИТУ «МИСиС»
Москва, Россия
m1801083@edu.misis.ru

Аннотация—в настоящее время широкое распространение получают беспилотные системы управления различными транспортными средствами, в том числе автомобилями. Управление беспилотным автомобилем предполагает решение задач, связанных с распознаванием объектов дорожной обстановки: пешеходов, автомобилей, препятствий (в виде ям и т. д.), дорожных знаков, разметки, светофоров. Автономные наземные транспортные средства должны быть способны воспринимать сигналы светофора, чтобы ездить по улицам вместе с водителями-людьми. В большинстве случаев водитель-человек может легко идентифицировать соответствующие сигналы светофоров. Методы глубокого обучения показали высокую производительность и точность в данной области. В работе рассматриваются несколько решений с открытым исходным кодом и сравниваются возможности распознавания светофоров по изображениям со стереокамеры на наборе данных LISA.

Ключевые слова — Компьютерное зрение, Детекция светофоров, Распознавание светофоров, Монокулярная камера, Беспилотные автомобили, YOLO, mAP, LISA

I. ВВЕДЕНИЕ

Изучением и проектированием беспилотных автомобилей занимаются многие университеты, научно-исследовательские центры, автомобильные и иные промышленные компании по всему миру с середины 1980-х годов. Известны разработки беспилотных транспортных средств, созданные гигантами автомобилестроения (Ford, Honda, Mercedes, Tesla, КАМАЗ совместно с Cognitive Technologies), ИТ-компаниями (Uber, Google, Яндекс) [1].

При создании системы управления беспилотного автомобиля важными задачами являются обнаружение и распознавание объектов дорожной обстановки. Для решения применяются технологии компьютерного зрения. В числе задач по обнаружению/распознаванию объектов в видеопотоке с камеры, установленной на автомобиль, можно выделить задачу идентификации световых сигналов, подаваемых светофорами.

Обнаружение и распознавание сигнала светофора включает в себя непосредственно его обнаружение и распознавание состояния (красный, зелёный или жёлтый). В литературе описаны различные способы решения этой задачи [2], в том числе и при наличии неблагоприятных погодных условиях (слабая освещённость, дымка, туман и т. д.) [3].

Методы глубокого обучения показали высокую производительность и способность к обобщению во многих областях и типах задач, таких как классификация [4, 5] и обнаружение [6]. Детекторы объектов общего назначения были хорошо изучены для задач, связанных с дорожным движением (таких как обнаружение светофоров, дорожных знаков и т. д.). YOLO [7] и R-CNN [8] являются двумя из этих современных детекторов. В работе рассматриваются и сравниваются достижения (с открытым исходным кодом) в области глубокого обучения для определения местоположения (и дальнейшего распознавания) светофоров по изображениям 2D-камеры.

Подходы, основанные на обучении, особенно те, которые используют глубокое обучение, требуют больших объёмов аннотированных данных, что не всегда есть в наличии. В настоящее время в свободном доступе есть зарубежные базы изображений с аннотациями светофоров [9, 10, 11]. Однако следует также заметить, что подходы, основанные на обучении, требуют больших вычислительных мощностей.

II. НАБОРЫ ДАННЫХ

Для обучения и тестирования рассматриваемых в данной работе нейросетей использовались некоторые наборы данных, как локальные, собранные авторами, так и открытые. Рассмотрим используемые открытые наборы.

A. LISA

Обширный набор общедоступных данных LISA [9], основанный на кадрах с дорог Сан-Диего штата Калифорния, содержит аннотированные видеопоследовательности, снятые при разном освещении (различное время суток) и погодных условиях с помощью стереокамеры (рисунок 1). Кроме того, в наборе данных представлены многосекционные светофоры, которые помимо цвета имеют и направления – всего 7 классов (рисунок 2): go, goForward, goLeft, stop, stopLeft, warning, warningLeft.

На рисунке 3 отображены некоторые нетривиальные случаи возникновения светофоров в кадре:

- смещение цветового тона и нарушение ореола из-за атмосферных условий и влияния других источников света (а, б, в, г);

- полное или частичное перекрытие другими объектами или непрямой угол обзора (д, е, ж, з);
- неполная форма светофора из-за неисправной или грязной лампы (и);
- стоп-сигналы автомобилей, отражения, рекламные щиты и огни пешеходных переходов (к);
- проблемы синхронизации между скоростью затвора камеры и рабочим циклом светофора (л, м).



Рис. 1. Примеры кадров при дневном и ночном освещении

B. DriveU

Набор данных DriveU [12] содержит около 230000 ручных аннотаций кадров, снятых в 11 разных городах при разных погодных условиях. Разметка кадров содержит в себе информацию об:

ограничивающих светофоры прямоугольниках;

состоянии (цвет светофора);

релевантности (относится ли светофор к текущему движению);

горизонтальной или вертикальной ориентации;

наличии визуального перекрытия;

количестве светодиодов, типе светофора (для пешеходов, велосипедистов или автомобилей).

Запись видеопоследовательностей велась при помощи стерео и широкоугольной камер. По стереопаре изображений также строится карта несоответствия [13] (рисунок 4).

III. НЕЙРОСЕТЕВЫЕ АРХИТЕКТУРЫ

A. Модификация YOLOv3 на фреймворке Darknet

В работе [14] решается задача распознавания релевантных светофоров для применения в беспилотных автомобилях. Авторы предлагают использовать детектирующую нейронную сеть, локализующую и распознающую светофоры в кадре, в сочетании с prior map – разметкой предопределённых маршрутов, в которой содержится информация о позиции, направлении и других характеристиках реальных светофоров, благодаря чему беспилотный автомобиль будет заранее иметь информацию о наличии светофора в кадре. Благодаря такому подходу авторам статьи удаётся определить, стоит ли брать во внимание состояние того или иного светофора в зависимости от того, относится ли он к текущему движению или попал в кадр случайно.



Рис. 2. Примеры классов состояния светофора: а) go, б) goForward, в) goLeft, г) stop, д) stopLeft, е) warning, ж) warningLeft



(g) (h)

Рис. 3. Примеры сложных ситуаций возникновения светофоров в кадре



Рис. 4. Пример кадра видеопоследовательности: два верхних изображения образуют стереопару, левое нижнее – соответствующий кадр широкоугольной камеры, правое нижнее – карта несоответствия

Разработка конечной системы велась в две стадии:

- в течение оффлайн-фазы были построены prior карты с использованием лидара и размечены релевантные светофоры;
- онлайн-фаза заключается в распознавании светофоров на кадрах видеопоследовательностей, выделении (при помощи разметки оффлайн-фазы) релевантных светофоров среди найденных (рисунок 6), и определении их состояния – «none», «off», «red», «green».
- Для текущей работы представляет интерес нейросетевая часть онлайн-фазы – детектирование и распознавание светофоров в кадре. Авторы [14] используют YOLOv3 [15], в основе которой лежит Darknet-53 (рисунок 7). Данная модель была обучена для детектирования и распознавания состояния светофора. Нейронная сеть на выходе имеет два класса – «red», в котором объединены красный и жёлтый цвет, и «green». Авторами отмечается, что красный и жёлтый цвет пришлось объединить в один класс из-за недостаточного количества данных с жёлтым цветом светофора, и как следствие невозможностью обучить нейронную сеть достаточного качества для данного класса.
- Открытые наборы данных DriveU и LISA были использованы для обучения и тестирования нейронной сети. Кроме того, был собран локальный датасет, названный авторами IARA, содержащий около 5000 размеченных светофоров и 3-классовую разметку («red», «green», «yellow»), на котором дополнительно проводилось тестирование. В качестве функции потерь использовалась mAP [16] – mean Average Precision для каждого класса, который в свою очередь, считается как площадь под кривой precision-recall.

$$\text{mAP} = \frac{1}{N} \sum_{i=1}^{N} AP_i \qquad (1)$$

YOLOv3 обучалась на 1500 батчах по 64 изображения в каждом и с константным learning rate = 0,001. Размер изображений составляет 608x608 пикселей – компромисс между скоростью и качеством.

Также в процесс обучения были включены: аугментация изображений при помощи изменения оттенка, насыщенности, экспозиции, батч-нормализация. Кроме того, каждые 10 батчей менялось разрешение изображений с 608x608 на разрешения, кратные 32, что делает модель более устойчивой к разным масштабам.

B. Сочетание SSD-MobileNet V1 и InceptionV3

Другой подход заключается в использовании MobileNet-SSD для локализации светофоров (нахождение их ограничивающих прямоугольников) и InceptionV3 для распознавания их состояния (цвета). Исходный код доступен по ссылке [17].

MobileNet [20] – эффективная и более лёгкая архитектура нейронной сети, которая может быть использована для классификации или извлечения признаков. Сочетание MobileNet-SSD фактически означает, что для извлечения признаков используется MobileNet (без последнего полно-

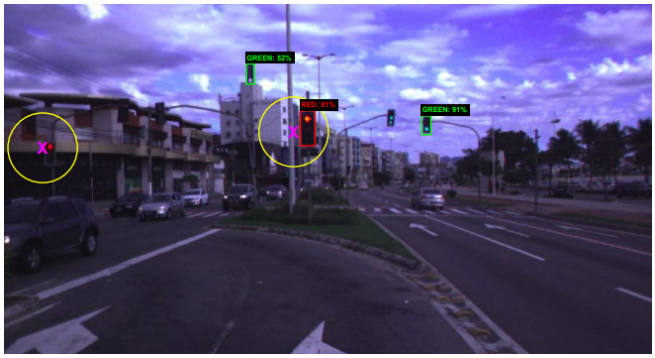


Рис. 5. Пример работы системы: 3D-координаты релевантных светофоров с лидара проецируются в 2D-координаты кадра и вокруг них строится 1.5-метровая сфера; релевантными светофорами в кадре считаются те, чьи центры попадают в эту сферу и максимально близко лежат к центру реального светофора

	Type	Filters	Size	Output
	Convolutional	32	3 × 3	256 × 256
	Convolutional	64	3 × 3 / 2	128 × 128
1×	Convolutional	32	1 × 1	
	Convolutional	64	3 × 3	
	Residual			128 × 128
	Convolutional	128	3 × 3 / 2	64 × 64
2×	Convolutional	64	1 × 1	
	Convolutional	128	3 × 3	
	Residual			64 × 64
	Convolutional	256	3 × 3 / 2	32 × 32
8×	Convolutional	128	1 × 1	
	Convolutional	256	3 × 3	
	Residual			32 × 32
	Convolutional	512	3 × 3 / 2	16 × 16
8×	Convolutional	256	1 × 1	
	Convolutional	512	3 × 3	
	Residual			16 × 16
	Convolutional	1024	3 × 3 / 2	8 × 8
4×	Convolutional	512	1 × 1	
	Convolutional	1024	3 × 3	
	Residual			8 × 8
	Avgpool		Global	
	Connected		1000	
	Softmax			

Рис. 6. Архитектура Darknet-53, которая лежит в основе YOLOv3

связного слоя) вместо VGG, а для локализации объекта – SSD.

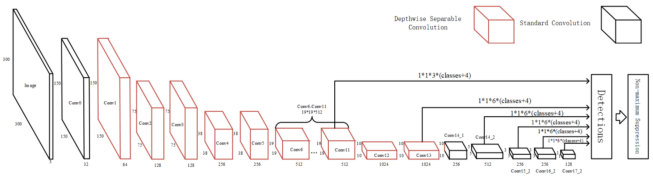


Рис. 7. Архитектура SSD-MobileNetV1

Итоговая архитектура [21] SSD-MobileNetV1 приведена на рисунке 8. Используются веса предобученной на датасете COCO [22] модели.

Для локализованных на кадре светофоров определяется класс их состояния при помощи нейронной сети InceptionV3 [23]. На рисунке 9 приведена архитектура данной сети.

Для классификации используются веса предобученной на наборе данных ImageNet [24] модели, доступные в TensorFlow. Модель дообучается на вырезанных с кадров светофорах набора данных LISA. В качестве функции потерь используется кросс-энтропия в задаче мультклассовой классификации (categorical cross-entropy) – softmax активация в сочетании с кросс-энтропийной функцией потерь. Дообучение длится 10 эпох с размером батча 32. Выходом данной сети является один из 7 классов, которые соответствуют классам в аннотациях набора данных LISA.

IV. СРАВНЕНИЕ

Сравним два описанных подхода. Для сравнения используется часть набора данных LISA – 7473 изображения с 18020 размеченными светофорами. Качество работы двух подходов складывается из качества работы локализующей и классифицирующей частей. Оценка локализации производится при помощи расчёта меры Жаккара (Intersection over Union, IoU) для каждой детекции. Найденные детектором светофоры связываются с существующей разметкой с порогом 10%. Введём следующие величины:

TP – детектор верно локализовал светофор (найдена соответствующая разметка – прямоугольники разметки и детекции пересекаются более, чем на 10%, по отношению к их общей площади).

FP – детектор нашёл светофор там, где его нет, то есть не найдено такого прямоугольника в разметке кадра, который пересекался бы с найденным более, чем на 10%.

FN – детектор не нашёл светофор, хотя он есть и для него есть разметка – пересечение менее, чем 10%.

Стоит отметить, что TN в данном случае не определена, так как это величина означает то, что детектор не определил светофор, где его действительно нет. По введённым величинам строятся такие функции оценок, как:

- $Precision = \dfrac{TP}{TP + FP}$ — сколько раз детектор нашёл светофор, где он действительно есть, по отношению к общему числу предсказанных светофоров;
- $Recall = \dfrac{TP}{TP + FN}$ — сколько светофоров нашёл детектор из действительно присутствующих в кадрах;
- $F_1 = 2 \cdot \dfrac{Precision \cdot Recall}{Precision + Recall} = \dfrac{2TP}{2TP + FP + FN}$ — оценка баланса между точностью (precision) и полнотой (recall).

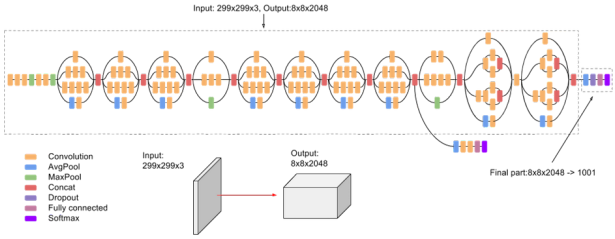


Рис. 8. Архитектура InceptionV3

Также в случае с видеопоследовательностями, можно использовать функции MOT [25] – MOTA (multiple object tracking accuracy), которая оценивает общую точность отслеживания и детекции, и MOTP (multiple object tracking precision) – оценка точности локализации светофоров (схожа с метрикой mAP [16]). Формулы (2) и (3) соответствуют формулам данных функций. При этом значения функции MOTA могут быть отрицательными – область значений $(-\infty, 1]$.

$$\text{MOTA} = 1 - \frac{FN + FP + IDS}{GT} \tag{2}$$

$$\text{MOTP} = \frac{1}{TP} \sum_i IoU_i \tag{3}$$

Здесь IoU_i – мера Жаккара i-го объекта на всей тестовой выборке. GT означает суммарное количество аннотаций, а IDS – количество потерь трека светофоров. В нашем случае показатель IDS не важен, так как производится оценка именно локализации, поэтому эта величина не участвует при расчёте показателя MOTA. Таблица 1 отображает количественные оценки для двух подходов.

Таблица I. Оценка детектирующей части

	YOLOv3 (детектор)	SSD-MobileNet V1
TP	15420	4048
FP	2095	12276
FN	2600	13972
Precision	0.88	0.25
Recall	0.86	0.22
F1	0.87	0.24
MOTA	0.74	−0.46
MOTP	0.59	0.44

Как видно из таблицы детектор YOLOv3 имеет значительно более высокие показатели, что означает, что он намного больше находит действительных светофоров и намного меньше ошибается, детектируя не относящееся к делу окружение. Примечательно, что значение функции MOTA для YOLOv3 достаточно близко к 1, в то время как оценка для SSD-MobileNet V1 имеет отрицательное значение.

В оценку классифицирующей части включены все объекты, которые входят в множество TP локализующей ча-

сти. Классифицирующая нейронная сеть InceptionV3 второго подхода на выходе имеет 7 классов, в то время как классификатор YOLOv3 предсказывает всего 2. Связи с этим матрицы ошибок имеют разные размеры. На рисунке 10 отображена матрица ошибок и отчёт о классификации, содержащий precision, recall и F1-меру [26, 27], для нейросети InceptionV3. Здесь номера классов 0–6 означают состояния светофора go, goForward, goLeft, stop, stopLeft, warning, warningLeft соответственно.

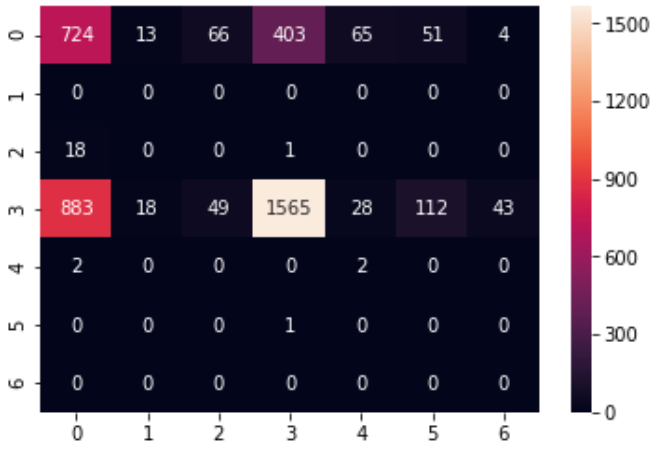


Рис. 9. Матрица ошибок и численная оценка работы InceptionV3

Как можно видеть, классы go и stop хоть и распознаются с не очень высоким значением F1-меры, но остальные классы не распознаются вообще. Такую оценку можно объяснить тем, что для большого количества классов и достаточного качества их распознавания очень важно иметь широкую и сбалансированную обучающую выборку. Такой выборки не было зафиксировано на этапе обучения данной сети.

Классифицирующая часть YOLOv3 на выходе имеет всего 2 класса. Поэтому можно определить некоторую переходную матрицу ошибок (рисунок 11а), которая содержала бы 7 реальных классов и 2 класса предсказываемых. Но больший смысл будет иметь матрица ошибок в обычном смысле (рисунок 11б) – здесь реальные классы go, goForward и goLeft объединены в класс go (метка 0), а классы stop, stopLeft, warning и warningLeft объединены в класс stop с меткой 1.

Численные оценки классификации этой нейросети имеют значения, близкие к 100% (рисунок 12). Такую сильную с предыдущей нейронной сетью разницу в качестве можно объяснить несколькими обстоятельствами: более долгое обучение на более релевантных наборах данных, меньшее число предсказываемых классов, более сбалансированная и широкая обучающая выборка, большее число тестовых картинок, так как более качественный детектор смог правильно локализовать большее число светофоров, которые затем и классифицировались.

Сравнивая классификаторы YOLOv3 и InceptionV3, можно заметить, что классы go и stop, наиболее широко представленные в датасете LISA, InceptionV3 распознаёт лучше всего. YOLOv3 распознаёт эти классы тоже хорошо (и даже лучше из-за упомянутых обстоятельств), но в случае с YOLOv3 лучше подготовлены данные для обучения. Это ещё раз показывает важность составления репрезентативной, широкой и сбалансированной обучающей выборки.

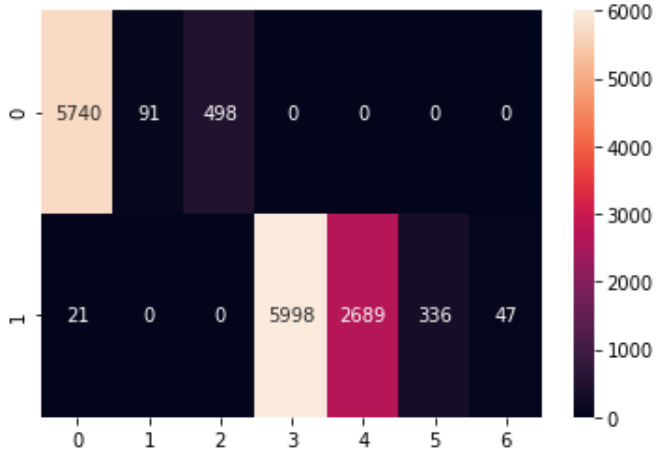


Рис. 10. Переходная 2x7 и обычная матрицы ошибок 2x2 нейросети YOLOv3

	precision	recall	f1-score	support
0	1.0000	0.9967	0.9983	6350
1	0.9977	1.0000	0.9988	9070
accuracy			0.9986	15420
macro avg	0.9988	0.9983	0.9986	15420
weighted avg	0.9986	0.9986	0.9986	15420

Рис. 11. Численная оценка качества работы классификатор YOLOv3

V. ЗАКЛЮЧЕНИЕ

Были рассмотрены основные наборы данных, на которых обучались и тестировались рассматриваемые нейронные сети. Приведены два подхода к детектированию – локализации и классификации – светофоров: YOLOv3, предложенная и обученная авторами работы [14], в которой решалась задача определения состояния релевантных светофоров, и сочетание предобученных SSD-MobileNet V1 и InceptionV3 [17]. Каждая сеть рассмотрена с точки зрения её архитектуры, процесса обучения, используемых для обучения и тестирования наборов данных.

Приведённые подходы были сравнены на части датасета LISA. Отдельно были оценены качество локализации и классификации светофоров. По полученным данным очевидно, что нейронная сеть YOLOv3, подготовленная авторами работы [14], имеет сильное преимущество перед альтернативным подходом, что объясняется разными обучающими процессами и разным качеством обучающих выборок. Притом сравнивались именно конкретные модели с конкретными весами. Для сравнения архитектур в целом нужны фиксированные наборы и процессы обучения и тестирования.

СПИСОК ЛИТЕРАТУРЫ

[1] “Driverless cars (global market)”, available at: https://www.tadviser.ru/index.php/Статья:Беспилотные_автомобили_(мировой_рынок) (Accessed: December 25, 2022).

[2] Jensen M.B., Philipsen M.P., Møgelmose A., Moeslund T.B., Trivedi M.M. “Vision for looking at traffic lights: Issues, survey, and perspectives”, IEEE Transactions on Intelligent Transportation Systems, 2016, no. 17, pp. 1800–181.

[3] Verma, M.P. and Singh, V.B.P. (2016) Traffic light recognition system: A computer vision based approach, International Journal For Science Technology And Engineering. Available at: https://ijste.org/Article.php?manuscript=IJSTEV3I3035 (Accessed: December 25, 2022).

[4] R. F. Berriel, A. T. Lopes, A. F. de Souza, and T. Oliveira-Santos, “Deep Learning Based Large-Scale Automatic Satellite Crosswalk Classification,” IEEE Geoscience and Remote Sensing Letters, vol. 14, pp. 1513–1517, Sept 2017.

[5] R. F. Berriel, F. S. Rossi, A. F. de Souza, and T. Oliveira-Santos, “Automatic Large-Scale Data Acquisition via Crowdsourcing for Crosswalk Classification: A Deep Learning Approach,” Computers & Graphics, vol. 68, pp. 32–42, Nov 2017.

[6] R. Guidolini, L. G. Scart, L. F. R. Jesus, V. B. Cardoso, C. Badue, and T. Oliveira-Santos, “Handling Pedestrians in Crosswalks Using Deep Neural Networks in the IARA Autonomous Car,” in 2018 International Joint Conference on Neural Networks (IJCNN), pp. 1–8, July 2018.

[7] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, “You only look once: Unified, real-time object detection,” in Proceedings of the IEEE conference on computer vision and pattern recognition, pp. 779–788, 2016.

[8] S. Ren, K. He, R. Girshick, and J. Sun, “Faster R-CNN: Towards realtime object detection with region proposal networks,” in Advances in neural information processing systems, pp. 91–99, 2015.

[9] Jensen M.B., Philipsen M.P., Møgelmose A., Moeslund T.B., Trivedi M.M. “Vision for looking at traffic lights: Issues, survey, and perspectives”, IEEE Transactions on Intelligent Transportation Systems, 2016, no. 17, pp. 1800–1815.

[10] Behrendt K., Novak L., Botros R. “A deep learning approach to traffic lights: Detection, tracking, and classification”, 2017 IEEE International Conference on Robotics and Automation (ICRA), 2017, pp. 1370–1377.

[11] Yu F., Xian W., Chen Y., Liu F., Liao M., Madhavan V., Darrell T. “Bdd100k: A diverse driving video database with scalable annotation tooling”, arXiv preprint arXiv, 2018, 1805.04687.

[12] A. Fregin, J. Muller, U. Krebel and K. Dietmayer, ”The DriveU Traffic Light Dataset: Introduction and Comparison with Existing Datasets,” 2018 IEEE International Conference on Robotics and Automation (ICRA), 2018, pp. 3376-3383.

[13] R. Hamzah, H. Ibrahim, ”Literature Survey on Stereo Vision Disparity Map Algorithms”, Journal of Sensors, 2016, pp. 1-23.

[14] Possatti, Lucas C. et al. “Traffic Light Recognition Using Deep Learning and Prior Maps for Autonomous Cars”, 2019 International Joint Conference on Neural Networks (IJCNN), 2019, pp. 1-8.

[15] J. Redmon, A. Farhadi. “YOLOv3: An Incremental Improvement”, ArXiv abs/1804.02767, 2018, pp. 1-6.

[16] M. Everingham, L. Van Gool, Williams, C.K.I. et al. “The PASCAL Visual Object Classes (VOC) Challenge”, International Journal of Computer Vision, 2010, vol. 88, pp. 303–338.

[17] SSD-MobileNet V1 detection and InceptionV3 classification source code, available at: https://www.kaggle.com/code/chandanakuntala/detection-classification-of-traffic-lights/notebook#CLASSIFICATION (Accessed: December 25, 2022).

[18] W. Liu, D. Anguelov, D. Erhan et al. “SSD: Single Shot MultiBox Detector”, European Conference on Computer Vision, 2015, pp. 1-17.

[19] K. Simonyan, A. Zisserman. “Very Deep Convolutional Networks for Large-Scale Image Recognition”, The 3rd International Conference on Learning Representations (ICLR2015), 2014, pp. 1-14.

[20] A. G. Howard et al. “MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Application.,” Howard, Andrew G., et al. ”Mobilenets: Efficient convolutional neural networks for mobile vision applications.” arXiv preprint arXiv:1704.04861, 2017, pp. 1-9.

[21] C. Xu and Y. Mao, “An improved traffic congestion monitoring system based on federated learning”, Information, 2020, vol. 11, no. 7, pp. 1–22.

[22] T. Lin, M. Maire, S. J. Belongie, Hays et. al. “Microsoft COCO: Common Objects in Context. European Conference on Computer Vision”, Computer Vision (ECCV2014), 2014, vol. 8693, pp. 740-755.

[23] C. Szegedy, V. Vanhoucke, S. Ioffe et. al. “Rethinking the Inception Architecture for Computer Vision”, 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2015, pp. 2818-2826.

[24] J. Deng, W. Dong, R. Socher, L. -J. Li, Kai Li and Li Fei-Fei, ”ImageNet: A large-scale hierarchical image database”, 2009 IEEE Conference on Computer Vision and Pattern Recognition, 2009, pp. 248-255.

[25] J. Luiten, A. Ošep, P. Dendorfer et al. “HOTA: A Higher Order Metric for Evaluating Multi-object Tracking”, International Journal of Computer Vision, 2021, vol. 129, pp. 548–578.

[26] Z. C. Lipton, C. P.Elkan, B. Narayanaswamy. “Thresholding Classifiers to Maximize F1 Score”, 2014 arXiv: Machine Learning, pp. 1-16.

[27] M. Sokolova, N. Japkowicz, S. Szpakowicz. “Beyond accuracy, F-score and ROC: a family of discriminant measures for performance evaluation”, Proceedings of Australasian joint conferenceon artificial intelligence, 2006, vol. 4304, pp. 1015-1021.