ГРНТИ 47.01.07, 47.01.09
ASJC 1707, 2207
OECD 1020, 1070

Исследование возможности детектирования светофоров

Л. С. Толстенко
кафедра инженерной кибернетики НИТУ «МИСиС»
Москва, Россия
student@edu.misis.ru

А. А. Клейменов
кафедра инженерной кибернетики НИТУ «МИСиС»
Москва, Россия
student2@edu.misis.ru

Аннотация — В настоящее время широкое распространение получают беспилотные системы управления различными транспортными средствами, в том числе автомобилями. Управление беспилотным автомобилем предполагает решение задач, связанных с распознаванием объектов дорожной обстановки: пешеходов, автомобилей, препятствий (в виде ям и т. д.), дорожных знаков, разметки, светофоров. Автономные наземные транспортные средства должны быть способны воспринимать сигналы светофора, чтобы ездить по улицам вместе с водителями-людьми. В большинстве случаев водитель-человек может легко идентифицировать соответствующие сигналы светофоров. Методы глубокого обучения показали высокую производительность и точность в данной области. В работе рассматриваются несколько решений с открытым исходным кодом и сравниваются возможности распознавания светофоров по изображениям со стереокамеры на наборе данных LISA.

Ключевые слова — Компьютерное зрение, Детекция светофоров, Распознавание светофоров, Стереокамера, Беспилотные автомобили, YOLO, mAP, LISA

I. ВВЕДЕНИЕ

Изучением и проектированием беспилотных автомобилей занимаются многие университеты, научно-исследовательские центры, автомобильные и иные промышленные компании по всему миру с середины 1980-х годов. Известны разработки беспилотных транспортных средств, созданные гигантами автомобилестроения (Ford, Honda, Mercedes, Tesla, КАМАЗ совместно с Cognitive Technologies), ИТ-компаниями (Uber, Google, Яндекс) [1].

При создании системы управления беспилотного автомобиля важными задачами являются обнаружение и распознавание объектов дорожной обстановки. Для решения применяются технологии компьютерного зрения. В числе задач по обнаружению/распознаванию объектов в видеопотоке с камеры, установленной на автомобиль, можно выделить задачу идентификации световых сигналов, подаваемых светофорами.

Обнаружение светофоров и формирование его состояния, может производиться на основе данных v2x, лидара, камер, а также с привлечением данных цифровой карты дорог (для формирования ROI).

Использование v2x требует наличия определенных датчиков как со стороны автомобиля так и со стороны инфраструктуры, что не всегда доступно. Использование лидара существенно облегчает задачу локализации светофора, однако такие решения применяются в системах с высоким уровнем автоматизации. Кроме-того лидар не способен идентифицировать сигнал светофора, поэтому не может использоваться как замена камерам технического зрения. Поэтому в статье акцент делается именно на решении задачи по изображениям.

II. АНАЛИЗ РАБОТ

Обнаружение и распознавание сигнала светофора включает в себя непосредственно его обнаружение и распознавание состояния (красный, зелёный или жёлтый). В литературе описаны различные способы решения этой задачи [2], в том числе и при наличии неблагоприятных погодных условиях (слабая освещённость, дымка, туман и т. д.) [3]. Методы глубокого обучения показали высокую производительность и способность к обобщению во многих областях и типах задач, таких как классификация [4, 5] и обнаружение [6]. Детекторы объектов общего назначения были хорошо изучены для задач, связанных с дорожным движением (таких как обнаружение светофоров, дорожных знаков и т. д.). YOLO [7] и R-CNN [8] являются двумя из этих современных детекторов. В работе рассматриваются и сравниваются достижения (с открытым исходным кодом) в области глубокого обучения для определения местоположения (и дальнейшего распознавания) светофоров по изображениям 2D-камеры.

Подходы, основанные на обучении, особенно те, которые используют глубокое обучение, требуют больших объёмов аннотированных данных, что не всегда есть в наличии. В настоящее время в свободном доступе есть зарубежные наборы с аннотациями светофоров: LISA [9], Bosch Small Traffic Lights [10]

и BDD100K [11]. Однако следует также заметить, что подходы, основанные на обучении, требуют больших вычислительных мощностей.

III. ПОСТАНОВКА ЗАДАЧИ

По кадру с камеры, установленной на автомобиле, требуется найти светофоры и определить состояние каждого из них.

На вход подаётся одно изображение видимого диапазона, кадр видеопоследовательности. На выходе для каждого найденного светофора ожидаются ограничивающий прямоугольник и класс состояния. Для сравнения приняты семь классов разметки LISA: go, goForward, goLeft, stop, stopLeft, warning, warningLeft.

Оценка проводится на части набора LISA: 7473 изображения и 18020 размеченных светофоров. Кадры сняты стереокамерой на дорогах Сан-Диего при разном времени суток и погоде. Детекторы используют двумерное изображение.

Светофор занимает малую часть кадра и может быть частично перекрыт, снят под углом или при слабом освещении; возможны блики и смещение цвета. Детекция считается верной, если пересечение с разметкой по мере Жаккара не меньше 10%. Сравниваются открытые модели с уже обученными весами. Число классов на выходе у них разное: YOLOv3 различает два состояния, связка SSD-MobileNet и InceptionV3 выдаёт семь классов LISA.

IV. НАБОРЫ ДАННЫХ

Для обучения и тестирования рассматриваемых нейросетей использовались открытые наборы, а также локальный набор IARA из работы [14]. Ниже разобраны открытые наборы.

A. LISA

Обширный набор общедоступных данных LISA [9], основанный на кадрах с дорог Сан-Диего штата Калифорния, содержит аннотированные видеопоследовательности, снятые при разном освещении (различное время суток) и погодных условиях с помощью стереокамеры (рисунок 1, 2).



Рис. 1. Примеры кадров при дневном и ночном освещении

Кроме того, в наборе данных представлены многосекционные светофоры, которые помимо цвета имеют и направления — всего 7 классов: go, goForward, goLeft, stop, stopLeft, warning, warningLeft.



Рис. 2. Примеры сложных ситуаций возникновения светофоров в кадре

B. DriveU

Набор данных DriveU [12] содержит около 230000 ручных аннотаций кадров, снятых в 11 разных городах при разных погодных условиях. Разметка кадра включает:

- ограничивающий прямоугольник светофора;
- состояние (цвет);
- релевантность (относится ли светофор к текущему движению);
- горизонтальную или вертикальную ориентацию;
- наличие визуального перекрытия;
- число светодиодов и тип светофора (для пешеходов, велосипедистов или автомобилей).

Запись видеопоследовательностей велась при помощи стерео и широкоугольной камер. По стереопаре изображений также строится карта несоответствия [13] (рисунок 3).



Рис. 3. Пример кадра видеопоследовательности: два верхних изображения образуют стереопару, левое нижнее – соответствующий кадр широкоугольной камеры, правое нижнее – карта несоответствия

V. НЕЙРОСЕТЕВЫЕ АРХИТЕКТУРЫ

A. Модификация YOLOv3 на фреймворке Darknet

В работе [14] решается задача распознавания релевантных светофоров для применения в беспилотных автомобилях. Авторы предлагают использовать детектирующую нейронную сеть, локализующую и распознающую светофоры в кадре, в сочетании с prior map – разметкой предопределённых маршрутов, в которой содержится информация о позиции, направлении и других характеристиках реальных светофоров, благодаря чему беспилотный автомобиль будет заранее иметь информацию о наличии светофора в кадре. Благодаря такому подходу авторам статьи удаётся определить, стоит ли брать во внимание состояние того или иного светофора в зависимости от того, относится ли он к текущему движению или попал в кадр случайно.

Разработка конечной системы велась в две стадии:

- в течение оффлайн-фазы были построены prior карты с использованием лидара и размечены релевантные светофоры;
- онлайн-фаза заключается в распознавании светофоров на кадрах видеопоследовательностей, выделении (при помощи разметки оффлайн-фазы) релевантных светофоров среди найденных (рисунок 4), и определении их состояния – «none», «off», «red», «green».

Для текущей работы представляет интерес нейросетевая часть онлайн-фазы – детектирование и распознавание светофоров в кадре. Авторы [14] используют YOLOv3 [15], в основе которой лежит Darknet-53. Данная модель была обучена для детектирования и распознавания состояния светофора. Нейронная сеть на выходе имеет два класса – «red», в котором объединены красный и жёлтый цвет, и «green». Авторами отмечается, что красный и жёлтый цвет пришлось объединить в один класс из-за недостаточного количества данных с жёлтым цветом светофора, и как следствие невозможностью обучить нейронную сеть достаточного качества для данного класса.

Открытые наборы данных DriveU и LISA были использованы для обучения и тестирования нейронной сети. Кроме того, был собран локальный датасет, названный авторами IARA, содержащий около 5000 размеченных светофоров и 3-классовую разметку («red», «green», «yellow»), на котором дополнительно проводилось тестирование. Качество детекции оценивалось метрикой mAP [16] (mean Average Precision): для каждого класса это площадь под кривой precision–recall.

$$\text{mAP} = \frac{1}{N}\sum_{i=1}^{N} AP_i \qquad (1)$$

YOLOv3 обучалась на 1500 батчах по 64 изображения в каждом и с константным learning rate = 0,001. Размер изображений составляет 608x608 пикселей – компромисс между скоростью и качеством.

Также в процесс обучения были включены: аугментация изображений при помощи изменения оттенка, насыщенности, экспозиции, батч-нормализация. Кроме того, каждые 10 батчей менялось разрешение изображений с 608x608 на разрешения, кратные 32, что делает модель более устойчивой к разным масштабам.

B. Сочетание SSD-MobileNet V1 и InceptionV3

Другой подход заключается в использовании MobileNet-SSD для локализации светофоров (нахождение их ограничивающих прямоугольников) и InceptionV3 для распознавания их состояния (цвета). Исходный код доступен по ссылке [17].

MobileNet [20] – эффективная и более лёгкая архитектура нейронной сети, которая может быть использована для классификации или извлечения признаков. Сочетание MobileNet-SSD фактически означает, что для извлечения признаков используется MobileNet (без последнего полносвязного слоя) вместо VGG [19], а для локализации объекта – SSD [18].



Рис. 4. Пример работы системы: 3D-координаты релевантных светофоров с лидара проецируются в 2D-координаты кадра и вокруг них строится 1.5-метровая сфера; релевантными светофорами в кадре считаются те, чьи центры попадают в эту сферу и максимально близко лежат к центру реального светофора

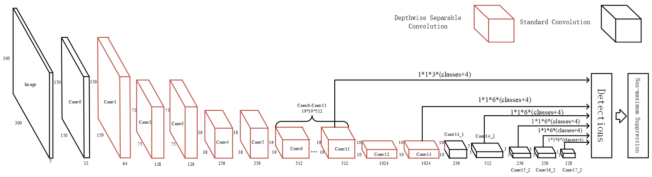


Рис. 5. Архитектура SSD-MobileNetV1

Итоговая архитектура SSD-MobileNetV1 [18, 20] приведена на рисунке 5. Используются веса предобученной на датасете COCO [21] модели.

Для локализованных на кадре светофоров определяется класс их состояния при помощи нейронной сети InceptionV3 [22]. На рисунке 6 приведена архитектура данной сети.

Для классификации используются веса предобученной на наборе данных ImageNet [23] модели, доступные в TensorFlow. Модель дообучается на вырезанных с кадров светофорах набора данных LISA. В качестве функции потерь используется кросс-энтропия в задаче мультклассовой классификации (categorical cross-entropy) – softmax активация в сочетании с кросс-энтропийной функцией потерь. Дообучение длится 10 эпох с размером батча 32. Выходом данной сети является один из 7 классов, которые соответствуют классам в аннотациях набора данных LISA.

VI. СРАВНЕНИЕ

Сравним два описанных подхода. Для сравнения используется часть набора данных LISA – 7473 изображения с 18020 размеченными светофорами. Качество работы двух подходов складывается из качества работы локализующей и классифицирующей частей. Оценка локализации производится при помощи расчёта меры Жаккара (Intersection over Union, IoU) для каждой детекции. Найденные детектором светофоры связываются с существующей разметкой с порогом 10%. Введём следующие величины:

TP – детектор верно локализовал светофор (найдена соответствующая разметка – прямоугольники разметки и детекции пересекаются более, чем на 10%, по отношению к их общей площади).

FP – детектор нашёл светофор там, где его нет, то есть не найдено такого прямоугольника в разметке кадра,

который пересекался бы с найденным более, чем на 10%.

FN – детектор не нашёл светофор, хотя он есть и для него есть разметка – пересечение менее, чем 10%.

Стоит отметить, что TN в данном случае не определена, так как это величина означает то, что детектор не определил светофор, где его действительно нет. По введённым величинам строятся такие функции оценок, как:

- $Precision = \dfrac{TP}{TP + FP}$ — сколько раз детектор нашёл светофор, где он действительно есть, по отношению к общему числу предсказанных светофоров;
- $Recall = \dfrac{TP}{TP + FN}$ — сколько светофоров нашёл детектор из действительно присутствующих в кадрах;
- $F_1 = 2 \cdot \dfrac{Precision \cdot Recall}{Precision + Recall} = \dfrac{2TP}{2TP + FP + FN}$ — оценка баланса между точностью (precision) и полнотой (recall).

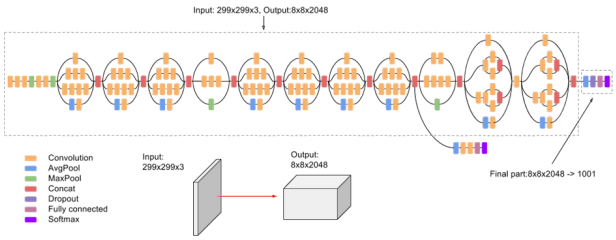


Рис. 6. Архитектура InceptionV3

Также в случае с видеопоследовательностями, можно использовать функции MOT [24] – MOTA (multiple object tracking accuracy), которая оценивает общую точность отслеживания и детекции, и MOTP (multiple object tracking precision) — средняя мера Жаккара для сопоставленных детекций. Формулы (2) и (3) соответствуют формулам данных функций. При этом значения функции MOTA могут быть отрицательными – область значений $(-\infty, 1]$.

$$\text{MOTA} = 1 - \frac{FN + FP + IDS}{GT} \tag{2}$$

$$\text{MOTP} = \frac{1}{TP} \sum_i IoU_i \tag{3}$$

Здесь IoU_i – мера Жаккара i-го объекта на всей тестовой выборке. GT означает суммарное количество аннотаций, а IDS – количество потерь трека светофоров. Треки в этом сравнении не строились, поэтому IDS принят равным нулю. Таблица I отображает количественные оценки для двух подходов.

Как видно из таблицы детектор YOLOv3 имеет значительно более высокие показатели, что означает, что он намного больше находит действительных светофоров и намного меньше ошибается, детектируя не относящееся к делу окружение. Примечательно, что значение функции MOTA для YOLOv3 достаточно близко к 1, в то время как оценка для SSD-MobileNet V1 имеет отрицательное значение.

Таблица I. Оценка детектирующей части

	YOLOv3 (детектор)	SSD-MobileNet V1
TP	15420	4048
FP	2095	12276
FN	2600	13972
Precision	0.88	0.25
Recall	0.86	0.22
F1	0.87	0.24
MOTA	0.74	−0.46
MOTP	0.59	0.44

В оценку классифицирующей части включены все объекты, которые входят в множество TP локализующей части. Классифицирующая нейронная сеть InceptionV3 второго подхода на выходе имеет 7 классов, в то время как классификатор YOLOv3 предсказывает всего 2. Связи с этим матрицы ошибок имеют разные размеры. На рисунке 7 отображена матрица ошибок и отчёт о классификации, содержащий precision, recall и F1-меру [25, 26], для нейросети InceptionV3. Здесь номера классов 0–6 означают состояния светофора go, goForward, goLeft, stop, stopLeft, warning, warningLeft соответственно.

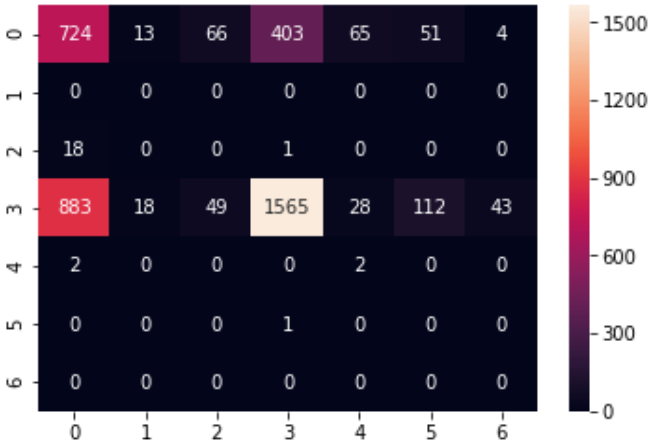


Рис. 7. Матрица ошибок и численная оценка работы InceptionV3

Как можно видеть, классы go и stop хоть и распознаются с не очень высоким значением F1-меры, но остальные классы не распознаются вообще. Такую оценку можно объяснить тем, что для большого количества классов и достаточного качества их распознавания очень важно иметь широкую и сбалансированную обучающую выборку. Такой выборки не было зафиксировано на этапе обучения данной сети.

Классифицирующая часть YOLOv3 на выходе имеет всего 2 класса: «red» и «green». На рисунке 8 показана переходная матрица ошибок: по столбцам семь классов разметки LISA, по строкам два предсказанных класса. Классы go, goForward и goLeft соответствуют «green», а stop, stopLeft, warning и warningLeft — «red», поскольку при обучении жёлтый сигнал был отнесён к красному.

Численные оценки классификации этой нейросети приведены в таблице II и близки к 100%. Такую сильную с предыдущей нейронной сетью разницу в качестве можно объяснить несколькими обстоятельствами: более долгое

обучение на более релевантных наборах данных, меньшее число предсказываемых классов, более сбалансированная и широкая обучающая выборка, большее число тестовых картинок, так как более качественный детектор смог правильно локализовать большее число светофоров, которые затем и классифицировались.

Сравнивая классификаторы YOLOv3 и InceptionV3, можно заметить, что классы go и stop, наиболее широко представленные в датасете LISA, InceptionV3 распознаёт лучше всего. YOLOv3 распознаёт эти классы тоже хорошо (и даже лучше из-за упомянутых обстоятельств), но в случае с YOLOv3 лучше подготовлены данные для обучения. Это ещё раз показывает важность составления репрезентативной, широкой и сбалансированной обучающей выборки.

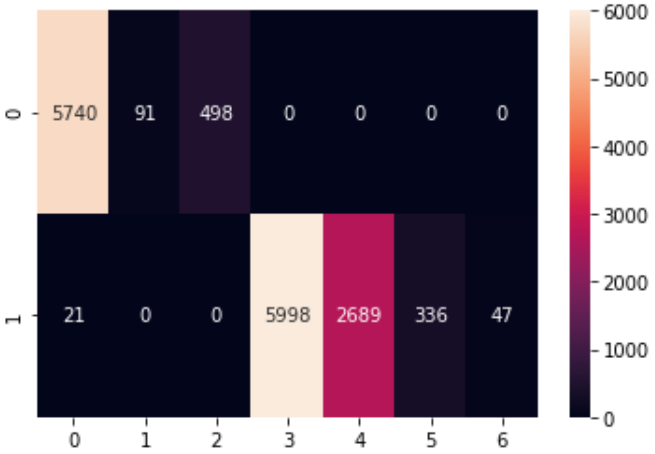


Рис. 8. Переходная матрица ошибок YOLOv3: семь классов разметки и два предсказанных класса

Таблица II. Численная оценка качества работы классификатора YOLOv3

	precision	recall	f1-score	support
0	1.0000	0.9967	0.9983	6350
1	0.9977	1.0000	0.9988	9070
accuracy			0.9986	15420
macro avg	0.9988	0.9983	0.9986	15420
weighted avg	0.9986	0.9986	0.9986	15420

VII. ЗАКЛЮЧЕНИЕ

Были рассмотрены основные наборы данных, на которых обучались и тестировались рассматриваемые нейронные сети. Приведены два подхода к детектированию – локализации и классификации – светофоров: YOLOv3, предложенная и обученная авторами работы [14], в которой решалась задача определения состояния релевантных светофоров, и сочетание предобученных SSD-MobileNet V1 и InceptionV3 [17]. Каждая сеть рассмотрена с точки зрения её архитектуры, процесса обучения, используемых для обучения и тестирования наборов данных.

Приведённые подходы были сравнены на части датасета LISA. Отдельно были оценены качество локализации и классификации светофоров. По полученным данным очевидно, что нейронная сеть YOLOv3, подготовленная авторами работы [14], имеет сильное преимущество перед альтернативным подходом, что объясняется разными обучающими процессами и разным качеством обучающих выборок. Притом сравнивались именно конкретные модели с конкретными весами. Для сравнения архитектур в целом нужны фиксированные наборы и процессы обучения и тестирования.

СПИСОК ЛИТЕРАТУРЫ

[1] “Driverless cars (global market)”, available at: https://www.tadviser.ru/index.php/Статья:Беспилотные_автомобили_(мировой_рынок) (Accessed: December 25, 2022).

[2] Jensen M.B., Philipsen M.P., Møgelmose A., Moeslund T.B., Trivedi M.M. “Vision for looking at traffic lights: Issues, survey, and perspectives”, IEEE Transactions on Intelligent Transportation Systems, 2016, no. 17, pp. 1800–1815.

[3] Verma, M.P. and Singh, V.B.P. (2016) Traffic light recognition system: A computer vision based approach, International Journal For Science Technology And Engineering. Available at: https://ijste.org/Article.php?manuscript=IJSTEV3I3035 (Accessed: December 25, 2022).

[4] R. F. Berriel, A. T. Lopes, A. F. de Souza, and T. Oliveira-Santos, “Deep Learning Based Large-Scale Automatic Satellite Crosswalk Classification,” IEEE Geoscience and Remote Sensing Letters, vol. 14, pp. 1513–1517, Sept 2017.

[5] R. F. Berriel, F. S. Rossi, A. F. de Souza, and T. Oliveira-Santos, “Automatic Large-Scale Data Acquisition via Crowdsourcing for Crosswalk Classification: A Deep Learning Approach,” Computers & Graphics, vol. 68, pp. 32–42, Nov 2017.

[6] R. Guidolini, L. G. Scart, L. F. R. Jesus, V. B. Cardoso, C. Badue, and T. Oliveira-Santos, “Handling Pedestrians in Crosswalks Using Deep Neural Networks in the IARA Autonomous Car,” in 2018 International Joint Conference on Neural Networks (IJCNN), pp. 1–8, July 2018.

[7] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, “You only look once: Unified, real-time object detection,” in Proceedings of the IEEE conference on computer vision and pattern recognition, pp. 779–788, 2016.

[8] S. Ren, K. He, R. Girshick, and J. Sun, “Faster R-CNN: Towards realtime object detection with region proposal networks,” in Advances in neural information processing systems, pp. 91–99, 2015.

[9] Jensen M.B., Philipsen M.P., Møgelmose A., Moeslund T.B., Trivedi M.M. “Traffic light detection: A learning algorithm and evaluations on challenging dataset”, 2015 IEEE 18th International Conference on Intelligent Transportation Systems, 2015, pp. 2341–2345.

[10] Behrendt K., Novak L., Botros R. “A deep learning approach to traffic lights: Detection, tracking, and classification”, 2017 IEEE International Conference on Robotics and Automation (ICRA), 2017, pp. 1370–1377.

[11] Yu F., Xian W., Chen Y., Liu F., Liao M., Madhavan V., Darrell T. “Bdd100k: A diverse driving video database with scalable annotation tooling”, arXiv preprint arXiv, 2018, 1805.04687.

[12] A. Fregin, J. Muller, U. Krebel and K. Dietmayer, ”The DriveU Traffic Light Dataset: Introduction and Comparison with Existing Datasets,” 2018 IEEE International Conference on Robotics and Automation (ICRA), 2018, pp. 3376-3383.

[13] R. Hamzah, H. Ibrahim, ”Literature Survey on Stereo Vision Disparity Map Algorithms”, Journal of Sensors, 2016, pp. 1-23.

[14] Possatti, Lucas C. et al. “Traffic Light Recognition Using Deep Learning and Prior Maps for Autonomous Cars”, 2019 International Joint Conference on Neural Networks (IJCNN), 2019, pp. 1-8.

[15] J. Redmon, A. Farhadi. “YOLOv3: An Incremental Improvement”, ArXiv abs/1804.02767, 2018, pp. 1-6.

[16] M. Everingham, L. Van Gool, Williams, C.K.I. et al. “The PASCAL Visual Object Classes (VOC) Challenge”, International Journal of Computer Vision, 2010, vol. 88, pp. 303–338.

[17] SSD-MobileNet V1 detection and InceptionV3 classification source code, available at: `https://www.kaggle.com/code/chandanakuntala/detection-classification-of-traffic-lights/notebook#CLASSIFICATION` (Accessed: December 25, 2022).

[18] W. Liu, D. Anguelov, D. Erhan et al. “SSD: Single Shot MultiBox Detector”, European Conference on Computer Vision, 2015, pp. 1-17.

[19] K. Simonyan, A. Zisserman. “Very Deep Convolutional Networks for Large-Scale Image Recognition”, The 3rd International Conference on Learning Representations (ICLR2015), 2014, pp. 1-14.

[20] A. G. Howard et al. “MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications”, arXiv preprint arXiv:1704.04861, 2017, pp. 1–9.

[21] T. Lin, M. Maire, S. J. Belongie, Hays et. al. “Microsoft COCO: Common Objects in Context”, Computer Vision (ECCV 2014), 2014, vol. 8693, pp. 740–755.

[22] C. Szegedy, V. Vanhoucke, S. Ioffe et. al. “Rethinking the Inception Architecture for Computer Vision”, 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2015, pp. 2818–2826.

[23] J. Deng, W. Dong, R. Socher, L. -J. Li, Kai Li and Li Fei-Fei, ”ImageNet: A large-scale hierarchical image database”, 2009 IEEE Conference on Computer Vision and Pattern Recognition, 2009, pp. 248–255.

[24] K. Bernardin, R. Stiefelhagen. “Evaluating Multiple Object Tracking Performance: The CLEAR MOT Metrics”, EURASIP Journal on Image and Video Processing, 2008, vol. 2008, pp. 1–10.

[25] Z. C. Lipton, C. P. Elkan, B. Narayanaswamy. “Thresholding Classifiers to Maximize F1 Score”, arXiv preprint arXiv:1402.1892, 2014, pp. 1–16.

[26] M. Sokolova, N. Japkowicz, S. Szpakowicz. “Beyond accuracy, F-score and ROC: a family of discriminant measures for performance evaluation”, Proceedings of the Australasian Joint Conference on Artificial Intelligence, 2006, vol. 4304, pp. 1015–1021.